

Du descriptif à « sont-elles différentes ? »

Revue du projet • distributions par groupe • deux Gaussiennes

Observer → décider → coder → expliquer

Une analyse défendable laisse quatre traces

 Nous comparons les raisonnements, pas seulement les chiffres finaux

Population

La ligne, le périmètre et le groupe sont nommés.

Décisions QC

Chaque action est reliée à une règle vérifiable.

Preuves

Tableaux et figures soutiennent la même **histoire**.

Frontière

Observation, explication et **généralisation** restent séparées.

Votre conclusion

Choisissez un résultat que vous pouvez défendre sans montrer tout votre code.

1

Observation

2

Preuve

3

Limite

4


**Prochaine
vérification**

Ce que le journal QC doit rendre explicite

Trois défauts de qualité ; une valeur rare ne constitue pas un quatrième défaut

constat	action de référence	effet sur l'effectif
ticket présent deux fois	garder une seule copie	-1
durée négative	exclure ; vraie durée inconnue	-1
étiquette « Email » avec espaces	corriger en email	0
trois durées rares mais plausibles	conserver et discuter	0

Résumés par groupe


 Lisez ensemble effectif, centre et dispersion ; les durées sont en minutes

channel	n	moyenne	médiane	écart-type	q1	q3	max
phone	599	89.7	89.3	18.8	76.8	101.8	158.0
chat	599	89.9	82.4	42.6	60.3	108.8	320.1
email	600	91.8	70.5	63.6	44.1	122.9	418.0

Question : quelle colonne change le plus votre lecture métier ?

La forme apparaît quand les groupes sont séparés


Trois panneaux • mêmes axes • classes de 10 min • observations en bas



Observez le pic, la symétrie et la queue. La densité lissée reste une vue optionnelle.

Le boxplot résume — il n'explique pas


Les points au-delà des moustaches demandent du contexte, pas une suppression automatique



Un même seuil de 180 minutes n'occupe pas la même position dans chaque groupe.

Fréquences observées à 180 minutes

Numérateur et dénominateur sont calculés à l'intérieur de chaque canal



Ce sont des fréquences de cet échantillon, pas encore des probabilités théoriques.

Trois groupes, trois mécanismes simulés


Vous avez d'abord décrit les données sans connaître leur générateur.

**C'est la bonne direction : observer → proposer un modèle →
vérifier ce qu'il explique.**

Un modèle est une simplification utile, pas l'étiquette vraie d'un histogramme.

Les mécanismes générateurs

 Barres : échantillon avec trois valeurs rares ajoutées • courbes : modèles de départ



Une forme suggère un modèle ; ici, nous connaissons le générateur de chaque groupe.

phone : une forme approximativement normale

— Générateur simulé : Normale(moyenne = 90, écart-type = 18)

Support

Valeurs théoriques sur toute la droite ; ici les valeurs négatives sont négligeables.

Forme

Approximativement symétrique autour de 90 minutes.

Repères

moyenne $\approx$ médiane ;
dispersion pilotée par l'écart-type.

chat : une forme lognormale

— Générateur simulé : Lognormale($\text{moyenne_log} = \log(80)$, $\text{écart_type_log} = 0,45$)

Support

Valeurs strictement positives.

Forme

Beaucoup de valeurs modérées, quelques valeurs beaucoup plus grandes.

Repères

moyenne > médiane ; la queue influence fortement l'écart-type et le maximum.

email : une forme exponentielle décalée

 Générateur simulé : 25 + Exponentielle(échelle = 65)

Support

Aucune valeur sous 25 minutes dans le mécanisme propre.

Forme

Fréquence élevée près du minimum, puis longue décroissance.

Repères

moyenne > médiane ; une queue très longue reste plausible.

Échantillon observé et modèle : deux objets différents

 Le modèle aide à raisonner au-delà des lignes, avec des hypothèses explicites

OBSERVÉ

- 1 798 lignes analysables
- fréquences empiriques
- statistiques et figures
- variabilité de l'échantillon

≠

MODÈLE

- famille et paramètres
- probabilités théoriques
- hypothèses simplificatrices
- prédictions à confronter

Deux groupes, deux formes gaussiennes


Les centres observés ne coïncident pas exactement.

Les populations sont-elles différentes — ou voyons-nous une fluctuation d'échantillonnage ?


Deux échantillons gaussiens qui se chevauchent

— Même $n = 35$; une moyenne observée par échantillon ; paramètres de population inconnus

Échantillon A • $n = 35$
moyenne observée = 100.7



Échantillon B • $n = 35$
moyenne observée = 106.5



Un écart est visible. Sa seule présence ne dit pas encore comment l'interpréter.

Sont-elles différentes ?

Votez OUI / NON / INFORMATION INSUFFISANTE, puis défendez votre réponse.

1

Citez l'écart

2

Citez le chevauchement

3

Nommez ce qui manque

Deux histoires restent compatibles avec l'image

La question porte sur les populations ; la figure ne montre que deux échantillons

HISTOIRE A

Même processus

L'écart observé vient de la variabilité entre échantillons.

HISTOIRE B

Processus différents

L'écart observé reflète une différence réelle entre populations.

Il nous faut une règle qui quantifie la compatibilité des données avec ces histoires.

Transformer la question en méthode formelle

H_0 / H_1

Statistique de test

**Distribution
d'échantillonnage**

p-value

Nous définirons, calculerons et interpréterons ces outils au prochain cours.

Aujourd'hui, la bonne réponse est une question mieux posée — pas un verdict improvisé.