

Projet individuel : comparer des distributions

Tickets support • qualité des données • fréquences observées

Observer → décider → coder → expliquer

Notre cible aujourd'hui

Passer d'un CSV imparfait à une conclusion descriptive défendable

Contrôler

Identifier les problèmes sans confondre valeur rare et erreur.

Comparer

Décrire centre, dispersion et forme à l'intérieur de chaque groupe.

Mesurer

Mesurer une fréquence observée avec le bon dénominateur.

Expliquer

Relier observation, preuve, limite et prochaine vérification.

Rappel : comment lire une distribution ?

Ecrivez quatre dimensions à examiner.

Rappel : comment lire une distribution ?

Ecrivez quatre dimensions à examiner.

1

Combien
d'observations ?

2

Où se situe le
centre ?

3

Quelle dispersion ?

4

Quelle forme ?

Une distribution se lit avec quatre manières

 Le groupe et l'unité doivent rester visibles à chaque comparaison

Effectif

n :

combien de lignes
analysables dans ce
groupe ?

Centre

moyenne et
médiane :

où se situe une
valeur typique ?

Dispersion

écart-type, IQR et
étendue :


à quel point les
valeurs
s'étalent-elles ?

Forme

symétrie, asymétrie,
queue, pics et
valeurs
inhabituelles.

Trois familles revues la semaine dernière

Reconnaître une forme suggère des questions ; cela ne prouve jamais la loi



Une ressemblance visuelle est une hypothèse de travail, pas une preuve.

Du mécanisme à la forme

Associez chaque mécanisme plausible à une famille, puis donnez une réserve.

1

Effets additifs autour d'un centre

2


Facteurs multiplicatifs positifs

3

Temps d'attente à taux stable


Moyenne et médiane : deux histoires possibles

Sous asymétrie, quelques grandes valeurs tirent davantage la moyenne



Comparez les deux, puis revenez à la forme et à la décision métier.

Trois lectures de la dispersion

 Aucune mesure n'est automatiquement la meilleure : chacune répond à une question

Écart-type

Dispersion autour de la moyenne ; sensible aux grandes distances.

IQR

Largeur des 50 % centraux : $q3 - q1$; robuste aux extrêmes.


Étendue

maximum – minimum ; montre l'amplitude, mais dépend de deux valeurs.


SD, IQR, étendue : trois repères

Rappel : dispersion autour du centre, intervalle central et extrêmes observés


Écart-type (SD)



IQR = $q_3 - q_1$



Étendue = max - min




SD et IQR décrivent la dispersion ; l'étendue dépend des deux extrêmes observés.

Et si la distribution est log-normale ?


La queue droite pèse sur le SD et l'étendue ; l'IQR décrit les 50 % centraux

Écart-type (SD)




moyenne $\pm$ 1 SD

IQR = $q_3 - q_1$



Un résumé central robuste

Étendue = max - min



Sensible aux extrêmes

Pour décrire le cœur sous asymétrie, médiane + IQR sont souvent plus lisibles.

Une valeur extrême apparaît : que faites-vous ?

Un service d'assistance suit les demandes d'aide de ses clients.

Un ticket = une demande enregistrée. Une ligne = un ticket résolu.

La durée = temps entre l'ouverture et la résolution, en minutes.

Classez les trois cas avant de proposer une action.

1

Durée : -12 minutes

2


Durée : 390 minutes

3

Même ticket sur deux lignes

Valeur inhabituelle ≠ erreur

La décision vient d'une règle et d'une vérification, pas de la seule distance




Un flag demande une enquête. Il ne commande pas une suppression.

Probabilité de queue : au-delà d'un seuil

 Mesure d'une fréquence observée ; aucun modèle théorique n'est requis

La queue rassemble les observations au-delà du seuil



Empirique : compter les observations dans la queue et diviser par l'effectif pertinent.

Projet individuel — tickets support

— Une responsable support veut comparer les temps de résolution par canal

Une responsable support vous confie un export CSV. Elle veut comprendre si les temps de résolution diffèrent entre canaux et quelles observations doivent être vérifiées avant de prendre une décision.

Votre conclusion doit répondre à cette question :

Comment le temps de résolution varie-t-il selon le canal, et quelles lignes faut-il vérifier avant de faire confiance au résultat ?

Votre mission

 Décrire les différences observées, puis préciser ce qu'elles permettent de conclure

Comment le temps de résolution varie-t-il selon le canal, et quelles lignes faut-il investiguer avant de faire confiance au résultat ?

- Travail individuel ; données entièrement simulées.
- Le CSV brut est immuable : toutes les décisions sont tracées.
- Référence et mécanismes générateurs : vendredi matin.

Le fichier : une ligne = un ticket

 Une mesure, un groupe ; l'identifiant sert uniquement au contrôle qualité

colonne	rôle	exemple / unité
channel	groupe catégoriel	phone / chat / email
resolution_minutes	mesure quantitative	durée en minutes
ticket_id	traçabilité seulement	identifiant du ticket

1 800 lignes • environ 600 par canal • deux variables à analyser

Un CSV brut n'est pas encore une population analysable

La qualité se vérifie avant les statistiques et reste visible après nettoyage

Identifiants

Manquants ?
dupliqués ? une
ligne
correspond-elle
encore à un ticket ?

Modalités

Espaces, casse,
variantes, groupe
vide ou inconnu.

Mesures


La durée est-elle
numérique,
renseignée et non
négative ?

Valeurs rares

Une durée élevée
est-elle impossible
ou seulement
inhabituelle ?

Votre pipeline en cinq checkpoints

— Chaque étape produit une sortie contrôlable avant la suivante



Après compréhension : `executer_pipeline.py` rejoue les cinq étapes.

Les livrables doivent se répondre

 Une conclusion défendable doit pouvoir remonter jusqu'aux lignes et aux décisions

TRACE

- pipeline Python reproductible
- tickets_support_nettoyes.csv
- journal_decisions_qualite.csv

PREUVE

- resume_par_groupe.csv
- frequences_empiriques_180_minutes.csv
- histogrammes séparés + boîte + conclusion

Vos points de départ pour coder

 Lisez un exemple, adaptez-le, puis expliquez la sortie obtenue

La consigne

PROJECT_BRIEF.md :
question, données et
livrables attendus.

Le squelette

pipeline_template/ : étape 01
exécutable ; étapes 02 à 05 à
compléter.

Les exemples

PYTHON_SNIPPETS.md :
lire, filtrer, calculer, tracer et
exporter.

Votre journée de développement

 Vous construisez votre pipeline jeudi ; la référence arrive vendredi matin

Jeudi matin

Après ce lancement : auditer, écrire les règles et préparer les données.

Jeudi après-midi

Décrire, visualiser, mesurer les fréquences, conclure et tout rejouer.

Vendredi matin

Comparer les démarches avec le pipeline de référence, puis interpréter.

Avant de coder : dessinez votre pipeline

Pour chaque étape, écrivez entrée → transformation → sortie → contrôle.

1

Nommez les fichiers

2

Placez le journal qualité

3

Indiquez où l'effectif change

Commencez par comprendre les lignes

Ouvrez `PROJECT_BRIEF.md` et `PYTHON_SNIPPETS.md` ; commencez par l'étape 01.

1 Nommer

unité • population • mesure •
groupe

2 Observer

aperçu • dimensions •
colonnes • valeurs brutes

3 Écrire

règles qualité avant
transformations

Checkpoint qualité

Avant l'étape 03, prouvez que votre population analysable est traçable.

1

**Lignes brutes →
analysables**

2

Problèmes → décisions

3

**Extrêmes conservés →
justification**

Checkpoint analyse

Pour chaque groupe, préparez une phrase soutenue par une statistique et une figure.

1

Centre

2

Dispersion + forme

3

Queue ≥ 180 min

Quatre phrases, quatre rôles

1

Observation

Ce que les données analysées montrent.

2

Preuve

La statistique ou la figure qui soutient l'observation.

3

Limite

Ce que cet échantillon ne permet pas d'affirmer.

4

À vérifier

L'information qui réduirait le plus l'incertitude.

Vendredi matin : pipeline de référence, comparaison des démarches, puis modèles.